

# Optimización de Campañas de Marketing Bancario

Predicción de suscripción a depósitos a plazo fijo mediante modelos clásicos y Deep Learning

**Mateo Bazán Rojas** — Científico de Datos  
5 de Mayo, 2026  
Dataset: Bank Marketing (UCI) · 45.211 contactos

Scikit-learn, TensorFlow

EDA + CV

## Contexto & Reto Principal

El banco portugués realiza campañas telefónicas para ofrecer depósitos a plazo. El objetivo es **predecir qué clientes se suscribirán** ("yes") para optimizar recursos y aumentar la eficiencia.

**88.73%**

No suscribe (clase 0)

**11.27%**

Sí suscribe (clase 1)

**~4.6k**

Registros positivos

⚠️ **Severo desbalance de clases** → Modelos tienden a predecir mayoritariamente "no". Se requiere estrategias específicas (class\_weight, métricas robustas como F1-score y Recall).



Distribución de suscripciones (countplot 'y')

88.7% "no" vs 11.3% "yes" – impacto directo en el rendimiento del modelo

## Análisis Exploratorio (EDA)

**Boxplot:** distribución de edad según suscripción

Los clientes que suscriben tienden a tener mediana de edad ligeramente superior (~40 vs 36 años).

**Suscripciones según tipo de trabajo**

"Retired", "student" y "management" muestran mayor tasa de conversión relativa.

🔍 **Insights clave:** La duración de la llamada (duration) influye pero es **data leakage**; se eliminó. Variables macroeconómicas (euribor3m, nr.employed) tienen alta correlación con la respuesta.

**Mapa de calor** de correlaciones entre variables numéricas

Euribor3m, nr.employed y emp.var.rate son los predictores más influyentes.

## Preprocesamiento Inteligente

🗑️ Eliminación columna **"default"** (20.8% unknown) y **"duration"** (data leakage)

🔢 One-Hot Encoding: 19 → **60 características**

÷ Escalado StandardScaler para SVM y Redes Neuronales

Partición estratificada 80/20 manteniendo proporción original

**32,950**

Train

**8,238**

Test

✅ **Shuffle + stratify** = train {0:88.7%, 1:11.3%} y test idéntico. Sin fugas de información.

**Flujo de preprocesamiento:**

- Eliminación de columnas con alto % de "unknown" (default) y data leakage (duration)
- One-Hot Encoding de variables categóricas (9 columnas → 41 nuevas)
- Escalado con StandardScaler (media=0, std=1)
- Partición train/test 80/20 estratificada (mantiene proporción de clases)

Diagrama conceptual del pipeline (sin imagen externa)

## Modelos Clásicos & Cross-Validation

Entrenamiento con **Decision Tree (max\_depth=5)**, **Random Forest (n=10)**, **SVM (kernel RBF)**. Validación cruzada estratificada (k=5) para robustez.

**0.903**Decision Tree  
Test Accuracy**0.890**Random Forest  
Test Accuracy**0.901**SVM (RBF)  
Test Accuracy

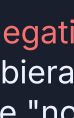
📊 **Resultados CV (promedio):** Accuracy ≈ 0.89-0.90 | F1-score ~0.37 | Recall ~0.26 (refleja dificultad del desbalance).

**Comparativa de Accuracy y F1-score por modelo en validación cruzada**  
Decision Tree, Random Forest y SVM – Accuracy y F1 promedio (k=5)

## Interpretabilidad: ¿Qué impulsa la suscripción?

[INSERTAR GRÁFICA: Top 10 Importancia (Random Forest)]

euribor3m, nr.employed, emp.var.rate, cons.price.idx, age, campaign, pdays...




[INSERTAR GRÁFICA: Curva ROC comparativa]

AUC ~0.85-0.88; SVM y Decision Tree tienen mejor compromiso.

💡 Las condiciones macroeconómicas (tasa Euribor, empleo) pesan más que atributos demográficos individuales.

## Mejor Modelo Clásico: Decision Tree (max\_depth=5)

Accuracy test: **0.903** | Diferencia train-test sólo 1.37% → excelente generalización, sin overfitting.



[INSERTAR MATRIZ DE CONFUSIÓN]

Verdaderos Positivos / Falsos Negativos cruciales

⚠️ **Falsos Negativos (FN):**

Cliente que hubiera suscrito pero el modelo predice "no" → pérdida de oportunidad de negocio.

✅ **Falsos Positivos (FP):** Llamada innecesaria, coste operacional bajo.

**Recomendación:** priorizar Recall (minimizar FN) ajustando umbral.

**Recall ~0.27** (por mejorar) | **Precisión ~0.56**

## Deep Learning: Perceptrón Multicapa

Evaluación de 3 arquitecturas profundas (TensorFlow/Keras) con 20 épocas, optimizador Adam, función sigmoide.

**MLP1**3 capas

ocultas: [64, 128, 128]

**MLP2**6 capas:

[64,64,128,128,256,256] + Dropout(0.3)

**MLP3**10

capas: todas 128 neuronas

🛑 Se añadió EarlyStopping en MLP2/MLP3 para mitigar sobreajuste. Batch size=32, validation\_split=20%.



[INSERTAR DIAGRAMA ARQUITECTURA RED NEURONAL]

## Conclusiones & Recomendaciones Estratégicas


- 🌟 **Modelo recomendado:** Decision Tree (max\_depth=5) por su equilibrio entre simplicidad, interpretabilidad y accuracy (90.3%).
  - 📊 Aunque SVM RBF logra accuracy ~90.1%, el árbol de decisión ofrece reglas claras para el negocio.
  - ⚖️ El **desbalance extremo** limita el recall; se sugiere usar técnicas como SMOTE o ajuste de umbral de clasificación para capturar más clientes potenciales.
  - 🧠 Deep Learning no supera a los modelos clásicos con los datos actuales, pero podría beneficiarse de más datos o aumento sintético.
  - 📈 Variables macroeconómicas (euribor3m, empleo) son drivers críticos: el banco debe segmentar campañas en contextos económicos favorables.
- 🔥 **Próximo paso:** Implementar modelo en producción con monitorización de recall, y realizar pruebas A/B para medir ROI real.

## Aprendizaje No Supervisado: Segmentación de Clientes

Análisis de clusters sobre los datos transformados (PCA previa) para descubrir patrones naturales sin usar la etiqueta de suscripción.

**Gráfico de varianza explicada** acumulada por componentes principales

n\_components\_95 = 39 componentes → retenemos 95% de varianza. PC1=9.9%, PC2=4.8% (total 14.7% visualizable en 2D).

**Método del codo** para seleccionar número de clusters en KMeans

Inercia disminuye suavemente; codo no definido, pero k=2 y k=4 son interpretables.

**KMeans k=2**Clusters

balanceados (~50% cada uno)

No separa bien las clases originales (sí/no)

**KMeans k=4**Tamaños:

13.5k, 13.5k, 5k, 9.1k

Mayor granularidad

**DBSCAN**eps=0.08, min\_samples=5

143 clusters + 1714 ruido

**Proyección PCA 2D:** clases originales, clusters KMeans y DBSCAN

Visualmente KMeans agrupa regiones densas; DBSCAN identifica ruido y muchos micro-clusters.

💡 **Insights de clustering:** Los clusters de KMeans no se alinean directamente con la variable objetivo, pero revelan segmentos conductuales. DBSCAN detecta clientes atípicos (ruido) que podrían ser casos especiales. El análisis no supervisado puede enriquecer campañas segmentando por perfil económico/educativo.

## Código, Documentación & Q&A

Repositorio completo con notebook de Colab, preprocesamiento, entrenamiento y análisis de resultados:

[github.com/mateobazan/bank\\_marketing\\_analysis](https://github.com/mateobazan/bank_marketing_analysis)



[INSERTAR CÓDIGO QR REAL hacia GitHub/Colab]

**Preguntas & Respuestas**

- ¿Cómo se gestionó el data leakage? (eliminación de 'duration')

- ¿Qué umbral de decisión maximiza el recall?

- Escalabilidad del modelo: inferencia en tiempo real.

✉️ [mateo.bazan@example.com](mailto:mateo.bazan@example.com)